

Traitement automatique du langage naturel

Václav Gregor

29 avril 2024

Table des matières

1	Introduction	1
2	Brève histoire du TALN	2
2.1	Approche symbolique	2
2.1.1	l'expérience Georgetown-IBM	2
2.1.2	ELIZA	4
2.1.3	ALPAC report	9
2.2	Approche statistique	10
2.3	Approche neuronale	10
3	Word embedding	11
3.1	Introduction	11
3.2	Principe sur un exemple simple	12
3.3	Sémantique distributionnelle	14
3.4	Démonstration	16
4	Conclusion	19

Résumé

Ces notes présentent un regard épistémologique sur le domaine du traitement automatique du langage naturel. Elles parlent de son histoire et de son développement, passant ensuite sur l'état actuel du domaine, où on regarde de plus près des techniques de l'apprentissage automatique et du deep learning.

Chapitre 1

Introduction

Nous allons en premier regarder l'histoire du traitement automatique du langage naturel (TALN en abrégé), en passant par ses trois approches principales : symbolique, statistique et neuronale. Il est impossible pour moi de donner un résumé complet de l'histoire de ce domaine, ainsi que de décrire chaque approche parfaitement. J'ai donc pris la décision de surtout utiliser des exemples de programmes et d'expériences spécifiques pour montrer comment le domaine a évolué.

Les insuffisances des deux premières approches nous emmèneront vers le TALN neuronal, c'est-à-dire des techniques utilisant l'apprentissage automatique (ML en abrégé pour "machine learning") ou le deep learning (DL en abrégé).

Ici on passera sur un autre exemple concret : Word2Vec, qui est une technique de ML légère et puissante en même temps, permettant de transformer des mots en vecteurs. On expliquera son fonctionnement et on regardera ses applications, surtout dans l'analyse sémantique.

Par la suite, on verra et essayera d'expliquer (au moins légèrement) les techniques actuelles - celles utilisant le deep learning.

A la fin, on discutera des problèmes actuels du TALN et son possible développement futur.

Chapitre 2

Brève histoire du TALN

2.1 Approche symbolique

2.1.1 l'expérience Georgetown-IBM

Sources de cette section :

- [1, Natural Language Processing (Wikipédia)]
- [2, Georgetown-IBM experiment (Wikipédia)]
- [3, The first public demonstration of machine translation...]

Le domaine a débuté dans les années 1950. Le premier résultat marquant et connu par le public général était l'expérience Georgetown-IBM en 1954. Il s'agissait d'une démonstration de traduction automatique du russe vers l'anglais, comme le contexte historique le voulait.

Le programme contenait 6 règles de grammaire, un vocabulaire de 250 éléments lexicaux (thèmes et désinences des mots compris), et était capable de traduire 60 phrases. Les phrases parlaient surtout de la chimie, les mathématiques, la communication, la métallurgie et les affaires militaires. Il est essentiel de noter que les phrases ont été choisies soigneusement par les auteurs du programme. Certaines règles et opérations du programme étaient spécifiques à un nombre limité de mots et de phrases d'entrée. Chaque mot russe du vocabulaire correspondait à un ou deux équivalents anglais. En plus, chaque mot avait 3 codes numériques associés, qui déterminaient la règle de grammaire à utiliser pour produire la sortie. Si cette description nous rappelle la notion de "hardcoding", ce n'est pas par hasard. Le programme était essentiellement un dictionnaire assez limité, qui cherchait la traduction correspondante pour chaque mot russe, et qui appliquait l'une des 6 règles pour rendre la phrase anglaise à la sortie plus correcte. Regardons ceci sur un exemple.

La phrase russe (en alphabet latin)

Vyelyichyina ugla opryedyelyayetsya otnoshenyiyem dlyini dugi k radiyusu.

Traduction française

L'ampleur de l'angle est déterminée par la relation entre la longueur de l'arc

et le rayon.

Traduction anglaise obtenue par le programme

Magnitude of angle is determined by the relation of length of arc to radius.

Regardons maintenant les informations que le programme avait à sa disposition pour traduire cette phrase.

entrée russe	équivalents anglais	code 1	code 2	code 3	règle
vyelyichyina	magnitude	***	***	**	6
ugl-	coal, angle	121	***	25	2
-a	of	131	222	25	2
opryedyelyayetsya	is determined	***	***	**	6
otnoshenyi-	relation, the relation	151	***	**	5
-yem	by	131	***	**	3
dlyin-	length	***	***	**	6
-i	of	131	***	25	3
dug-	arc	***	***	**	6
-yi	of	131	***	25	3
k	to, for	121	***	23	2
radius-	radius	***	221	**	6
-u	to	131	***	**	3

TABLE 2.1 – Exemple de traduction (Georgetown-IBM)

Le premier mot (vyelyichyina) n'a qu'un seul équivalent anglais (magnitude) et son premier code étant vide (***) infère la règle 6 : la traduction est simplement copiée à la sortie.

sortie partielle : magnitude

Le deuxième mot (ugla) est séparé en thème (ugl-) et désinence (-a). Le thème (ugl-) appelle la règle 2 avec son code 1 (121). La règle 2 va chercher à trouver 221 ou 222 comme le code 1 de la prochaine entrée (-a). On trouve 222 pour le code 1 de l'entrée "-a", et donc on choisit le deuxième équivalent de "ugl-" pour la sortie (angle).

sortie partielle : magnitude angle

L'entrée suivante (-a) appelle la règle 3 avec son code 1 (131). Cette règle va regarder si le code 2 de l'entrée précédente est égal à 23. Comme ce code est vide (***), on sélectionne le seul équivalent de "-a" et on inverse l'ordre des deux mots (ce qui produit "of angle").

sortie partielle : magnitude of angle

Le reste de la traduction serait trouvé similairement, on va donc s'arrêter ici. Je pense que ce petit exemple est suffisant pour illustrer le fait que le programme ne fait que suivre bêtement les règles "hardcodées" par les chercheurs. Avant d'être programmé, ce processus qu'on vient d'essayer a été testé par des personnes avec aucune connaissance en russe, pour vérifier qu'il produit des résultats corrects sur les phrases données. Si on essaie de

trouver une analogie, on peut imaginer qu'on donne un dictionnaire russe-anglais à une personne anglophone qui ne parle pas russe, on lui demande de traduire des phrases, mais en plus de ça, on lui donne aussi une liste d'instructions à suivre pour produire des phrases plus naturelles (en n'utilisant que le dictionnaire pour traduire).

En gros, la valeur de l'expérience Georgetown-IBM repose dans l'analyse de la grammaire russe et dans l'invention des 6 règles qui permettent de traduire les phrases prédéterminées sans aucune réflexion. Cette tâche a ensuite été passée à un ordinateur.

Ce qui est intéressant, c'est que cette expérience était vue comme un énorme succès. Voici quelques extraits d'article des journaux américains contemporains pour illustrer ce point.

It is expected by IBM and Georgetown University, which collaborated on this project, that within a few years there will be a number of "brains" translating all languages with equal aplomb and dispatch. (Kenny, Christian Science Monitor)

The girl who operated 701 did not understand a word of Soviet speech and yet more than 60 Soviet sentences were given to the "brain" which translated smoothly at the rate of about 2.5 lines a second. (Kenny, Christian Science Monitor)

The "brain" didn't even strain its superlative versatility and flicked out its interpretation with a nonchalant attitude of assumed intellectual achievement. (Kenny, Christian Science Monitor)

On remarque surtout l'utilisation du mot "brain", alors que le programme n'était qu'une suite de branchements IF ELSE. Une jolie illustration du fait que dans les années 1950, les ordinateurs étaient vus comme des cerveaux mystérieux par une partie significative de la population. Ceci a permis à cette démonstration d'arriver à son but : attirer l'attention du public et du gouvernement américain et obtenir des financements pour la recherche future dans ce domaine.

2.1.2 ELIZA

Sources de cette partie :

[4, ELIZA (Wikipédia)]

[5, L'article original de Joseph Weizenbaum sur ELIZA.]

[6, Does GPT-4 pass the Turing test ? (étude de UC San Diego)]

[7, Computer Power and Human Reason (livre de Weizenbaum)]

Introduction

En 1966, ELIZA est créé par Joseph Weizenbaum - un programme pour explorer l'interaction entre les humains et les machines. ELIZA est capable

d'utiliser les règles définies dans un script externe pour simuler une conversation. Le programme repose sur l'application du pattern-matching et d'une méthodologie de substitution, qui seront expliqués sur un exemple. Son script le plus célèbre : DOCTOR, simule un psychothérapeute de l'école Rogerienne ("Rogerian school" en anglais). Ce qui est important à retenir est que dans cette approche psychothérapeutique, le psychologue répète souvent les paroles du patient à ce dernier. Ce script permet donc à ELIZA de garder l'illusion d'une conversation avec un humain, sans savoir rien sur le monde réel. Citons Weizenbaum qui explique ce point :

This mode of conversation was chosen because the psychiatric interview is one of the few examples of categorized dyadic natural language communication in which one of the participating pair is free to assume the pose of knowing almost nothing of the real world. If, for example, one were to tell a psychiatrist "I went for a long boat ride" and he responded "Tell me about boats", one would not assume that he knew nothing about boats, but that he had some purpose in so directing the subsequent conversation. It is important to note that this assumption is one made by the speaker. [5, L'article original de Joseph Weizenbaum sur ELIZA]

Fonctionnement général

Le fonctionnement général d'ELIZA peut être décrit ainsi : le texte entré par l'utilisateur est inspecté pour y trouver l'un des "mots clés". Si un mot clé est trouvé, l'entrée est transformée en appliquant une règle associée avec ce mot clé. Si aucun mot clé n'est trouvé, une réponse générale ne dépendant que de l'entrée est formulée, ou bien une transformation déjà utilisée avant est appliquée. Les mots clé et leurs transformations sont définis dans le script externe. ELIZA peut donc travailler avec n'importe quel script, et c'est ce dernier qui détermine sa "personnalité".

Weizenbaum résume ceci en 5 problèmes techniques :

- L'identification du mot clé le plus important, car il peut y en avoir plusieurs dans une seule entrée.
- L'identification d'un contexte minimal dans lequel le mot clé apparaît. Par exemple, si le mot clé est "you", est-ce qu'il est suivi par "are" ? Dans ce cas, une assertion sur ELIZA est probablement faite par l'utilisateur. Une telle information peut nous aider avec le choix de transformation.
- Le choix d'une transformation appropriée et l'exécution de cette transformation.
- Un mécanisme qui permettra à ELIZA de répondre d'une façon "intelligente" si aucun mot clé est trouvé.
- Un mécanisme pour faciliter l'édition et extension d'un script. Ce point nous intéressera peu, car il n'est pas essentiel pour comprendre

le fonctionnement d'ELIZA.

Les transformations

Le principe des transformation est expliqué très bien par Weizenbaum dans son article original (ce qui suit en est une analogie) : considérons la phrase "Je suis très malheureux". Supposons qu'un étranger (pourquoi pas un Slovaque) avec un niveau de français limité a entendu cette phrase mais n'a compris que le début de la phrase : "Je suis". Le Slovaque a quand-même retenu le reste de la phrase, mais il ne sait pas ce qu'il veut dire. Souhaitant répondre à la personne, il remplace "Je suis" par "Ca fait longtemps que tu es" et ensuite il répète le reste de la phrase originale pour formuler sa réponse : "Ca fait longtemps que tu es malheureux?". Le Slovaque a appliqué un certain modèle à la phrase originale, qui l'a séparée en deux parties : "Je suis" et "très malheureux". Il a ensuite utilisé une transformation qui lui a permis de répondre même s'il ne comprenait pas la phrase entière. Cette transformation lui dit qu'à toute phrase de la forme "Je suis BLABLA", il est possible de répondre avec "Ca fait longtemps que tu es BLABLA ?", sans savoir ce que le BLABLA veut dire. Voilà ce que fait ELIZA.

Décomposition et réassemblage

Plus formellement, considérons la phrase "It seems that you hate me". On l'a décompose ainsi en quatre parties :

(1)It seems that (2)you (3)hate (4)me

Supposons que l'étranger ne comprend que les parties 2 et 4 de cette phrase. Les mots qu'il a compris représente le/-s mot/-s clé pour ELIZA. Ici, il s'agit des mots "you" et "me". Une façon générale pour lui de répondre pourrait être "What makes you think I hate you?". C'est-à-dire il jette la partie (1), il traduit les parties qu'il a compris - "you" devient "I" et "me" devient "you" et finalement il ajoute une phrase de base "What makes you think" devant tout ça.

On peut alors représenter la règle de décomposition que l'étranger a utilisé plus formellement :

(0 YOU 0 ME)

où le 0 correspond à un nombre quelconque de mots dans la phrase originale. Voici la règle de réassemblage correspondante.

(WHAT MAKES YOU THINK I 3 YOU)

où le 3 correspond à la troisième partie de la décomposition de la phrase originale - ce qui se trouve entre les seuls mots compris "you" et "me".

Si on prend la phrase "It seems that you hate", la règle de décomposition (0 YOU 0 ME) échoue, comme on n'arrive pas à trouver le mot "ME". On voit donc le besoin d'avoir plusieurs décompositions pour un seul mot clé, qui vont être testées une par une sur la phrase d'entrée. En plus, on aura plusieurs réassemblages possibles pour chaque décomposition. On peut alors représenter les données correspondantes à un mot clé ainsi :

$$\{K : [D_1, R_{1,1}, R_{1,2} \dots R_{1,m_1}], \\ [D_2, R_{2,1}, R_{2,2} \dots R_{2,m_2}], \\ \dots \\ [D_n, R_{n,1}, R_{n,2} \dots R_{n,m_n}]\}$$

où à un mot clé K , on associe n règles de décomposition $D_1 \dots D_n$, et à chaque règle de décomposition D_i on associe m_i règles de réassemblage $R_1 \dots R_{m_i}$. Un script pour ELIZA n'est alors qu'une liste de telles structures. Un dictionnaire qui a comme clés les mots clés du script est construit une fois que le script est chargé par ELIZA. En plus, les clés du dictionnaire sont hachées pour permettre à ELIZA de déterminer rapidement si un mot lu est un mot clé ou pas, car la plupart des mots que ELIZA va lire ne sont pas des mots clés. Regardons d'autres mécanismes qui sont présents dans ELIZA.

Substitution

On remarque aussi que dans l'exemple au-dessus, on a substitué le mot "you" à l'entrée par "I" à la sortie. De telles substitutions sont aussi définies dans la liste d'un mot clé donné.

exemple.

Classement des mots clés

ELIZA contient aussi un mécanisme pour classer les mots clé par importance. D'où le besoin pour ceci ?

exemple.

Pendant le scan de la phrase à l'entrée, ELIZA utilise une autre liste pour tenir compte des mots clé rencontrés, et pour les garder ordonnés par leur importance.

Dernière réassemblage utilisé

Lorsqu'une règle de réassemblage correspondante à une décomposition est utilisée, son indice est sauvegardé. Lors de la prochaine utilisation de

cette décomposition, cet indice va permettre à ELIZA d'utiliser la règle de réassamblage qui suit la dernière utilisée. Elle va utiliser chaque réassamblage avant de revenir sur un qu'on a déjà vu. Ceci rend les réponses de ELIZA plus riches.

Mémoire

Un mécanisme très simple, mais qui pourtant produit des résultats impressionnants est celui de la mémoire. Il permet à ELIZA de répondre à l'utilisateur même si aucun mot clé n'est trouvé dans l'entrée. La réponse va donc faire référence à quelque chose que l'utilisateur a dit précédemment. Considérons la structure suivante :

```
(MEMORY MY
(0 YOUR 0 = LETS DISCUSS FURTHER WHY YOUR 3)
(0 YOUR 0 = EARLIER YOU SAID YOUR 3)
...)
```

Le mot clé "MY" va alors servir à insérer des phrases dans la mémoire. Lorsque ce mot clé est choisi comme le plus important par le mécanisme de classement à la fin de la lecture de l'entrée, l'une des transformations de la structure de mémoire est choisie aléatoirement. Une copie de l'entrée est alors transformée et sauvegardée dans une pile. Le reste du processus continue comme on l'a déjà décrit. Si jamais une entrée future n'admet aucun mot clé, une réponse est dépilée de la pile de mémoire et elle est envoyée à l'utilisateur. Ce mécanisme ajoute beaucoup à l'effet que ELIZA pouvait produire sur ces utilisateur.

Discussion

Dans son livre *Computer Power and Human Reason : From Judgement to Calculation*, Weizenbaum nous raconte des anecdotes parlant des premiers utilisateurs de ELIZA, qui devenait parfois attachés émotionnellement au programme. Ou l'exemple de sa secrétaire, qui a apparemment demandé à Weizenbaum de sortir de la pièce pour qu'elle puisse avoir une vraie conversation avec ELIZA.

I had not realized that extremely short exposures to a relatively simple computer program could induce powerful delusional thinking in quite normal people. [7]

On pourrait alors considérer ELIZA comme l'un des premiers programmes capables de tenter le test de Turing, et aussi capable de le passer sous certaines conditions. D'après une étude réalisée à UC San Diego [6] qui demandait à ses volontaires de converser par message soit avec un programme, soit avec un vrai humain, et de décider si la personne avec laquelle ils parlaient

était un humain ou pas, ELIZA était plus performante que GPT 3.5. Ceci est assez incroyable, considérant la simplicité et légèreté d'ELIZA d'un point de vue informatique. Weizenbaum a réussi à créer un programme qui ne sait rien sur le monde réel, et qui arrive quand-même à tenir une conversation avec un humain en restant relativement convaincant. Tout ça en 1966 !

Il était intéressant de comparer ELIZA au programme de l'expérience de Georgetown-IBM. On voit que seulement en 12 ans, la complexité et les capacités des programmes ont augmenté énormément. Je m'en suis rendu compte aussi en écrivant ce rapport. Il m'a suffi de comparer le temps que j'ai mis à expliquer le fonctionnement du programme Georgetown-IBM, avec le temps que j'en ai mis pour ELIZA. Je trouve cette comparaison juste, car je crois que le niveau de détail que j'ai atteint dans les deux cas est à peu près le même.

2.1.3 ALPAC report

Sources de cette partie :

[8, L'article original]

[9, ALPAC : The (in)famous report]

ALPAC (Automatic Language Processing Advisory Committee) était une commission de 7 scientifiques, dont le dirigeant John R. Pierce (un ingénieur américain), 2 linguistes, 2 chercheurs en traduction automatique (TA en abrégé), un psychologue et un chercheur en IA, créée par le gouvernement américain en 1964. Son but était d'évaluer le progrès de la recherche en linguistique informatique, plus spécifiquement en traduction automatique. Son rapport publié en 1966 est devenu célèbre pour sa critique de la TA comme domaine de recherche, ainsi que pour l'explicitation du manque de résultats utiles après une dizaine d'années de recherche.

Le rapport se concentre sur les applications pratiques de la TA, et comme on se trouve aux États-Unis en 1966, ces applications consistent exclusivement à traduire des textes (surtout scientifiques) du russe vers l'anglais. Le rapport répète que l'utilisation des systèmes de TA tels qu'ils sont actuellement n'est pas envisageable. Les textes traduits automatiquement ne sont pas très compréhensibles, ils ont donc besoin d'être revus et corrigés par un humain. Ceci contredit la prémisse de la traduction automatique, qui justement est censée être *automatique*. D'après le rapport, il serait plus économique et efficace de garder la tâche de traduction chez les traducteurs humains, et de rediriger les financements ailleurs.

Les effets de ce rapport ont été sévères pour le domaine, même s'il y a des parties du rapport qui sont contestables. On peut aussi remarquer qu'il essaye d'accentuer "l'échec" de la TA. Par exemple, le rapport fait une comparaison entre le programme de l'expérience Georgetown-IBM (dont on a déjà parlé) et les systèmes de TA actuels (10 ans plus tard), en essayant

de montrer que les résultats de ce premier étaient plus impressionnants. Je pense que nous allons tous être d'accord qu'une telle comparaison est ridicule. Comparer un "programme-dictionnaire" capable de traduire 60 phrases spécifiquement choisies, avec des modèles qui traduisent des textes quelconques (même si pas parfaitement) n'est pas très correcte. Le rapport gonfle aussi les financements qui ont été attribués aux recherches en TA. 20 millions de dollars d'après le rapport, mais en réalité il s'agissait plutôt de 12 ou 13 millions de dollars.

On peut dire que le rapport n'a vu la traduction automatique que comme un outil des motivations stratégiques et politiques de l'époque, qui était déjà censé fonctionner, et qui n'en était pas capable. Il est vrai que les résultats de la TA étaient parfois décevants, et qu'une application dans la vraie vie n'était pas encore possible. Malheureusement, le rapport n'a pas reconnu le potentiel de la TA, et sa publication a beaucoup endommagé le développement du domaine.

2.2 Approche statistique

2.3 Approche neuronale

Chapitre 3

Word embedding

3.1 Introduction

Le word embedding (en français : vectorisation de mots, plongement lexical, ou bien enchâssement de mots) est la notion de représenter un mot par un vecteur (réel), en sorte que ça code leur sémantique. L'idée principale étant que dès qu'on a des vecteurs, on peut faire des maths dessus. Et si ce codage de nos mots est bien fait, on s'attend à ce que les opérations mathématiques qu'on peut faire sur les vecteurs correspondent à des relations sémantiques entre nos mots.

Par exemple, on pourrait se demander quel est le vecteur le plus proche du vecteur qui représente le mot "chien". Si notre word embedding est bien fait, on s'attend à trouver dans sa proximité les vecteurs des mots comme "chiot", "Rex", "berger", etc.

On peut aussi additionner des vecteurs. Imaginons qu'on prend le vecteur du mot "repas", et on lui ajoute le vecteur du mot "viande". On voudrait que le vecteur résultat soit proche des vecteurs des mots comme "steak haché", "poulet rôti", "boef bourgignon", "guláš", etc.

La soustraction nous donne l'exemple le plus connu du word embedding, qui mathématiquement s'exprime ainsi :

$$\overrightarrow{roi} - \overrightarrow{homme} + \overrightarrow{femme} \approx \overrightarrow{reine}$$

Comme le dernier exemple : ça serait quoi la moyenne entre les vecteurs des mots "nuit" et "jour" ?

Grâce à cette représentation numérique, on obtient des nombreuses possibilités d'analyse sémantique de texte. On peut trouver les mots les plus similaires à un mot donné, et on peut faire pareil pour les phrases (moteurs de recherche, autocorrection). Pour obtenir le vecteur d'une phrase, il suffit de prendre la moyenne des vecteurs de ses mots. On peut analyser de différents documents et obtenir un résumé de leur contenu, de l'opinion

ou de l'émotion qui se trouve dedans. On peut mesurer la similarité entre document, sémantiquement parlant.

Les word embedding sont également essentiels pour l'apprentissage automatique. Ici, ils servent d'un prétraitement avant de passer les données au modèle de ML ou de DL. On a bien besoin de représenter nos données textuelles par quelque chose mathématique (des vecteurs), si on veut les passer à un modèle d'apprentissage automatique. Ainsi le nombre de cas d'usage du word embedding devient énorme.

3.2 Principe sur un exemple simple

Regardons maintenant un word embedding concret, très simple. Ce qui suit est essentiellement une traduction de [10, *Understanding word vectors*, Allison PARISH] en français. Considérons la table dans fig. 3.1 qui décrit quelques animaux en fonction de leur mignonnerie et leur taille.

	cuteness (0–100)	size (0–100)
kitten	95	15
hamster	80	8
tarantula	8	3
puppy	90	20
crocodile	5	40
dolphin	60	45
panda bear	75	40
lobster	2	15
capybara	70	30
elephant	65	90
mosquito	1	1
goldfish	25	2
horse	50	50
chicken	25	15

FIGURE 3.1 – Word embedding d'animaux.

Sur fig. 3.2, vous pouvez voir ce que ça donne en tant qu'espace de vecteurs 2D.

Cet exemple très simple est bien un word embedding : on a associé un vecteur 2d à chaque mot de notre table. Certes, d'une façon arbitraire, mais pourtant intuitive, et on croit que les valeurs qu'on a choisies codent bien les relations sémantiques entre nos animaux. On peut désormais tester les opérations dont on a parlé dans la partie précédente, pour voir si notre word embedding est bien fait.

Remarquons que le cheval et le dauphin sont proches l'un de l'autre. Deux animaux assez mignons et grands, d'après notre embedding (même si




FIGURE 3.2 – Word embedding d’animaux en 2D.

les dauphins ne sont parfois pas si mignons que ça...). Similairement pour le chaton et le chiot, deux animaux qui sont petits et très mignons, ou bien la tarantule et le moustique, très petits et pas du tout mignons. Prenons maintenant la différence entre le chaton et le poussin et ajoutons-la à la tarantule. Voyons ceci sur la fig. 3.3.

La pointe du vecteur bleu est le plus près du vecteur qui représente le hamster. Mathématiquement, cela s’écrirait :

$$\vec{c} - \vec{p} + \vec{t} \approx \vec{h}$$

Et en français :

Les tarentules sont aux hamsters ce que les poussins sont aux chatons.

C’est-à-dire un animal un peu plus petit et beaucoup moins mignon, ce qui est assez correcte. On suppose ici que les poussins sont moins mignons que les chatons... bon, il y a pas mal de gens qui seraient d’accord, on le laisse comme ça.

On a vu un word embedding sur quelques mots d’animaux, qui nous a permis d’analyser leur sémantique. On associe un vecteur à chaque mot en fonction de la mignonnerie et la taille de l’animal, on regarde la relation mathématique entre deux mots (le poussin et le chaton), et on utilise cette information pour déduire une **relation sémantique** entre deux mots différents (la tarantule et le hamster). Incroyablement simple et puissant en même temps.




FIGURE 3.3 – La tarantule au hamster.

3.3 Sémantique distributionnelle

Dans les applications réelles des word embeddings, le principe reste le même, mais le processus devient plus compliqué. Les mots à l'entrée vont être beaucoup plus nombreux - on peut imaginer un ensemble des centaines de milliers de mots. Ensuite, comment fait-on pour associer un vecteur à chacun de ces mots ? Dans l'exemple précédent, on a attribué des valeurs arbitraires à chaque mot manuellement, ce qui ne sera plus possible à cause de leur quantité. On veut aussi quelque chose de général et automatisable. On veut qu'un ordinateur soit capable de produire le word embedding, sans devoir philosopher sur la question : est-ce qu'un poussin est plus mignon qu'un chaton ? Heureusement qu'il y a la hypothèse distributionnelle.

Hyp 3.3.1 (hypothèse distributionnelle) *La sémantique d'un mot est déterminée par son contexte - les mots qui l'entourent dans le texte.*

Cette hypothèse due à J. R. Firth (linguiste britannique des années 1950s) nous dit que ce qui détermine la sémantique d'un mot, ce sont les mots qui se trouvent à ses côtés dans la phrase. Prenons les mots *beau*, *froid* et *chaud*, et regardons des exemples de phrases qui les emploient :

Il a fait bien **froid** hier.
 Par contre, il va faire hyper **chaud** aujourd'hui.
 Il fera très **beau** demain !
 Est-ce qu'il va faire très **froid** mardi ?

Il s'agit des phrases naturelles, et on peut déjà observer que les trois mots ont une tendance à se trouver entre un adverbe (bien, hyper, très) et un mot indiquant un jour (hier, aujourd'hui, demain, mardi). Par la hypothèse distributionnelle, ces trois mots devraient avoir une sémantique similaire, car ils ont le même contexte. Ceci est tout à fait vrai, tous les trois mots sont utilisés pour décrire le temps. Une telle sémantique s'appelle alors comme la hypothèse - distributionnelle.

Cette approche nous permettra d'associer des vecteurs aux mots d'une entrée de taille arbitraire, et en plus automatiquement. Regardons sur un exemple :

It was the best of times, it was the worst of times.

Comme le contexte, on considérera juste le voisin gauche et le voisin droite de chaque mot. La première ligne de la table 3.1 contient tous les contextes possibles. Même si "it was the" a deux occurrences dans notre phrase, le contexte correspondant "it _ the" ne se trouve qu'une fois dans la table. On prend les contextes sans répétition. La première colonne contient tous les mots, aussi sans répétition. Finalement, pour chaque mot, les valeur dans sa ligne indique combien de fois il se trouve dans le contexte spécifié.

g	DÉBUT _ was	it _ the	was _ best	the _ of	best _ times	of _ it	times _ was	was _ worst	worst _ times	of _ FIN
it	1	0	0	0	0	0	1	0	0	0
was	0	2	0	0	0	0	0	0	0	0
the	0	0	1	0	0	0	0	1	0	0
best	0	0	0	1	0	0	0	0	0	0
of	0	0	0	0	1	0	0	0	1	0
times	0	0	0	1	0	0	0	0	0	1
worst	0	0	0	1	0	0	0	0	0	0

TABLE 3.1 – Contextes d'une phrase.

On observe que les vecteurs des mots *best* et *worst* sont les mêmes : $[0, 0, 0, 1, 0, 0, 0, 0, 0, 0]$. La distance euclidienne entre les deux est zéro, et par la hypothèse distributionnelle, ces deux mots devraient avoir la même signification. Ce n'est pas tout à fait le cas, car *best* et *worst* sont des antonymes, pas des synonymes. Pourtant, leurs sémantiques sont très proches, et on a réussi à le reconnaître. Cette façon d'obtenir un word embedding s'appelle *count-based* : on compte le nombre de fois qu'un mot apparaît dans un contexte pour obtenir son vecteur.

Dans l'exemple précédent, notre corpus (l'entrée textuelle) consistait en une phrase, ce qui nous a donné 10 contextes : 10 positions possible pour un mot. En réalité, on est emmené à utiliser des corpus beaucoup plus grands, où on aurait donc des milliers ou mêmes des millions de contextes possibles - des vecteurs à des milliers ou des millions de dimensions. On se doute que ce ne serait pas très pratique. Grâce à des techniques de réduction de dimensionnalité, on peut transformer des vecteurs énormes en vecteurs de dimension

plus raisonnable : environ 100-300, sans perdre trop d'information. Je laisse les détails de cette transformation de côté (c'est des maths).

3.4 Démonstration

Il existe de nombreuses collections de vecteurs déjà prêtes qu'on peut télécharger et utiliser dans nos projets. Dans l'exemple suivant, on utilisera la collection *en_core_web_lg*, disponible dans la bibliothèque Python *SpaCy*. Il s'agit de 514 000 vecteurs de mots anglais à 300 dimensions, provenant de plusieurs sources. Ça fait beaucoup de vecteurs.

Cette démonstration est elle aussi fortement inspirée par [10, *Understanding word vectors*, Allison PARISH] (tout ce que j'ai changé c'est le livre), comme je ne suis pas très original et surtout je n'ai pas le temps de développer un exemple intéressant moi-même. Pour cela, il faudrait vraiment plonger dans le sujet, et ce n'est pas possible, sachant qu'on est à la fin du semestre :)

Je vais utiliser l'un de mes livres préféré comme le corpus : *Joyland*, écrit par Stephen King. Pour vous mettre un peu dans l'ambiance, *Joyland* parle d'un jeune homme du nom Devin Jones. Devin a 21 ans, il fait des études d'anglais, il rêve de devenir écrivain, mais sinon il ne sait pas quoi faire de sa vie. Sa copine vient de le larguer, et donc au lieu de passer les vacances d'été avec elle, il les passe à travailler dans un parc d'attraction. Ici il trouve des amis et un boulot qui lui plaît. Un peu plus tard, il fait enfin la connaissance de la jolie femme blonde qui habite dans l'une des maisons qui bordent la plage que Devin traverse pour se rendre au parc. Il y a aussi un mystère à résoudre (c'est du Stephen King) : une suite de meurtres de jeunes filles, toutes dans des parcs d'attraction, incluant celui où Devin passe son été. Tout ça dans une vibe des années 70 en Caroline du Nord.

On va charger le texte de *Joyland* comme l'entrée, et on va utiliser les vecteurs déjà disponibles grâce à SpaCy pour analyser ce texte. On va utiliser que des mots unique du livre, et en plus que des mots du livre qui ont un vecteur dans le modèle. Les relations sémantiques sont déterminées par le modèle déjà entraîné, mais les résultats vont nous quand même donner des information sur notre entrée spécifique. Cet exemple représente ce qui se passe lorsqu'on utilise un word embedding pour analyser la sémantique d'un document, par exemple pour déterminer l'émotion principale d'un commentaire. Voici le code (les commentaires sont en anglais mais je crois que ça ira) :

```
1  from __future__ import unicode_literals
2  import spacy
3  import numpy as np
4
5  # load the word vectors into our model
6  nlp = spacy.load("en_core_web_lg")
```

```

7  # read the text (joyland.txt) and create our corpus (doc)
8  doc = nlp(open("joyland.txt").read())
9
10 # keep only alphabetical words and lowercase them
11 tokens = list(set([w.text.lower() for w in doc if w.is_alpha
12 ]))
13 # keep only words that have a vector in our model
14 tokens = list(filter(lambda x: nlp.vocab.has_vector(x),
15 tokens))
16 # extract sentences
17 sentences = list(doc.sents)
18
19 """ Calculates the cosine similarity between two vectors. """
20 def cos_sim(u, v):
21     return np.dot(u, v)/np.linalg.norm(u)/np.linalg.norm(v)
22
23 """ Returns the vector corresponding to the input string. """
24 def vec(s : str):
25     return np.array(nlp.vocab[s].vector)
26
27 """ Return the word corresponding to the given vector by
28 looking
29 for the closest vector in the model.
30 """
31 def word(v):
32     max_sim = -1
33     res = ""
34     for w in nlp.vocab:
35         if w.has_vector:
36             sim = cos_sim(v, w.vector)
37             if sim > max_sim:
38                 max_sim = sim
39                 res = w.text
40     return res
41
42 """ Return the list of most similar words to the given one.
43 """
44 def closest_words(token_list, v, n=5):
45     return sorted(token_list,
46                   key=lambda x: cos_sim(vec(x), v),
47                   reverse=True)[:n]
48
49 """ Return closest sentences """
50 def closest_sents(sents_list, sent, n=5):
51     return sorted(sents_list,
52                   key=lambda x: cos_sim(x.vector, nlp(sent).
53 vector),
54                   reverse=True)[:n]

```

Regardons quelques exemples de mots les plus similaires. Il y a des similarité purement grammaticales, mais aussi des similarités sémantiques très intéressantes.

```

1  >>> print(closest_words(tokens, vec("food")))

```

```

2 ['food', 'seafood', 'meat', 'cooking', 'meal']
3 >>> print(closest_words(tokens, vec("love")))
4 ['love', 'loves', 'loved', 'loving', 'lovers']
5 >>> print(closest_words(tokens, vec("friend")))
6 ['friend', 'ladyfriend', 'girlfriend', 'friends', 'boyfriend']
7 >>> print(closest_words(tokens, vec("dog")))
8 ['dog', 'dogs', 'cat', 'pet', 'pup']
9 >>> print(closest_words(tokens, vec("happy")))
10 ['happy', 'unhappy', 'grateful', 'excited', 'happily']

```

Un exemple classique consiste à trouver le mot à mi-chemin entre *day* et *night*.

```

1 >>> v = (vec("day") + vec("night"))/2
2 >>> print(closest_words(tokens, v))
3 ['day', 'night', 'morning', 'evening', 'afternoon']

```

Ajoutons maintenant le vecteur de *meat* à *food*. Toujours un bon dîner mais un peu plus carnivore.

```

1 >>> print(closest_words(tokens, vec("food")))
2 ['food', 'seafood', 'meat', 'cooking', 'meal']
3 >>> print(closest_words(tokens, vec("food") + vec("meat")))
4 ['food', 'meat', 'seafood', 'chicken', 'pork']

```

Chapitre 4

Conclusion

Bibliographie

- [1] Les contributeurs de Wikipédia. *Natural language processing*. Consulté en avril 2024.
- [2] Les contributeurs de Wikipédia. *Georgetown-IBM experiment*. Consulté en avril 2024.
- [3] John HUTCHINS. *The first public demonstration of machine translation : the Georgetown-IBM system, 7th January 1954*. Consulté en avril 2024 (version archivée du site original sur <https://hutchins-web.me.uk/>).
- [4] Les contributeurs de Wikipédia. *ELIZA*. Consulté en avril 2024.
- [5] Joseph WEIZENBAUM. *ELIZA - A Computer Program For the Study of Natural Language Communication Between Man And Machine*, 1966.
- [6] Cameron R. JONES, Benjamin K. BERGEN, UC San Diego. *Does GPT-4 pass the Turing test ?*, 2024. Consulté en avril 2024 (version archivée de l'article original).
- [7] Joseph WEIZENBAUM. *Computer Power And Human Reason : From Judgement to Calculation*. W. H. Freeman and Company, 1976. Page 7.
- [8] Automatic Language Processing Advisory Committee. *Language and Machines : Computers in Translation and Linguistics* (connu plutôt sous "ALPAC report"). 1996. Version archivée de l'article sur le site.
- [9] John HUTCHINS. *ALPAC : the (in)famous report. MT News International*, June(14) :9–12, 1996. Version archivée de l'article sur le site.
- [10] Allison PARISH. *Understanding word vectors*. Consulté en avril 2024.